

Jensen Huang 访谈核心 Takeaway | Dwarkesh Patel 对话

访谈来源：Dwarkesh Patel 播客 — *"Will Nvidia's Moat Persist?"*

嘉宾：Jensen Huang（黄仁勋），Nvidia 创始人兼 CEO

一、Nvidia 的护城河：不只是芯片，而是整个生态系统

Jensen 将 Nvidia 的核心使命定义为“将电子转化为 token”——输入是电子，输出是 token，中间是 Nvidia。这个转化过程涉及的工程、科学和发明远未被充分理解，因此很难被完全商品化。

Nvidia 的真正护城河不是单一的技术优势，而是一个多层次的飞轮效应：上游供应链的深度绑定、下游需求的巨大规模、CUDA 生态的开发者网络，以及遍布全球每一朵云的安装基数。

Jensen 透露 Nvidia 已经做出了近千亿美元的上游采购承诺，但更关键的是那些“隐性承诺”——他亲自向供应链上下游的 CEO 们阐释 AI 产业的未来规模，说服他们提前投资产能。这些供应商之所以愿意为 Nvidia 而非其他人下注，是因为 Nvidia 的下游需求足够大，能够消化他们的产能。

关键洞察：供应链瓶颈（CoWoS、HBM、EUV）都是 2-3 年可解决的问题，真正的长期瓶颈是能源政策。Nvidia 通过“预取瓶颈”（prefetching bottlenecks）的方式，提前数年识别并解决供应链卡点。

二、TPU 与 ASIC 的竞争：可编程性才是王道

面对 TPU 的挑战，Jensen 做出了清晰的区分：Nvidia 构建的是**加速计算**（accelerated computing），而非仅仅是张量处理单元。CUDA 的可编程性允许研究者不断发明新算法——混合 SSM 架构、扩散与自回归融合、MoE 并行化——这些创新才是 AI 每年实现 10x-50x 性能飞跃的真正来源，而摩尔定律每年只能带来约 25% 的提升。

Jensen 直接挑战了竞争对手：TPU 和 Trainium 都不敢参加 InferenceMAX 和 MLPerf 基准测试来证明自己的成本优势。他断言 Nvidia 在全球范围内拥有最佳的性能/TCO 比和性能/功耗比，没有任何平台能够证明相反。

关键洞察：Nvidia 的 GPU 就像 F1 赛车——任何人都能开到 100 英里/小时，但要推到极限需要 Nvidia 的专业团队。Nvidia 为 AI 实验室提供的优化服务经常能将模型性能提升 2-3 倍，这直接



化为客户的收入。

三、CUDA 生态的不可替代性

即便大型超算客户有能力编写自己的内核，CUDA 的价值依然不可替代，原因有三：

生态丰富度： CUDA 支持所有框架（Triton、vLLM、SGLang、verl、NeMo RL 等），当系统出问题，你可以信任底层基础设施是可靠的——“你希望问题永远出在你自己的代码里，而不是下面那座代码山里。”

安装基数： 全球数亿 GPU 的存量意味着你写的软件可以在所有地方运行。对于 AI 创业公司来说，选择最丰富、最普及、生态最完善的架构是理性的唯一选择。

全云覆盖： Nvidia 是唯一一家在所有主要云平台（Google、AWS、Azure、OCI）以及本地部署中都存在的加速计算平台。

四、投资 AI 实验室：一个迟来的觉悟

Jensen 坦率地承认了一个战略失误：他没有及早意识到 OpenAI 和 Anthropic 这样的前沿实验室需要的投资规模远超传统 VC 的能力范围。当 Anthropic 需要数十亿美元级别的投入时，Nvidia 还没有做好这种规模投资的准备，导致 Anthropic 转向了 Google 和 AWS——这也是 Anthropic 大量使用 TPU 和 Trainium 的历史原因。

Jensen 表示这个错误不会再犯。Nvidia 现在已经投资了 OpenAI（据报道约 300 亿美元）和 Anthropic（约 100 亿美元），并且愿意在 IPO 前支持这些公司的规模化发展。但他同时强调 Nvidia 不挑选赢家——“要么照顾所有人，要么让他们自己照顾自己”——因为他记得 Nvidia 自己当年在 60 家图形公司中是最不被看好的那个。

五、为什么 Nvidia 不做云？“尽可能少做”的哲学

Jensen 反复强调 Nvidia 的核心哲学：**do as much as needed, as little as possible**（做尽可能多的必要之事，但尽可能少做）。如果 Nvidia 不做的事情，没有人会做（比如 CUDA、NVLink、cuLitho），那就必须做。但如果世界上已经有很多人在做（比如云服务），Nvidia 就应该支持生态而非亲自下场。

这就是为什么 Nvidia 投资 CoreWeave、Nscale、Nebius 等新兴 AI 云，而不是自己成为超算运营商。Nvidia 的目标是让 AI 和美国技术栈能够触达尽可能多的行业和国家，而不是把自己变成一个金融公司。

六、定价与供应分配：不做价格投机者

Nvidia 从不根据供需关系调整价格——报价就是报价，不会因为需求暴涨而涨价。分配原则是先到先得（FIFO），基于采购订单（PO）而非出价高低。Jensen 认为这种可预测性是 Nvidia 成为产业基础设施的关键：你可以像信任时钟一样信任 Nvidia 每年都会交付下一代架构，token 成本每年降低一个数量级。

他还透露 Nvidia 与 TSMC 之间没有法律合同，完全基于 30 年的信任关系运作——“有时我占便宜，有时我吃亏，但总体上这段关系不可思议。”

七、对华芯片出口：一场激烈的辩论

这是访谈中最具张力的部分。Jensen 强烈反对限制对华芯片出口，核心论点如下：

中国已经拥有大量算力。 中国是全球第二大计算市场，制造全球 60% 的主流芯片，拥有全球 50% 的 AI 研究人员，能源充裕到拥有“幽灵数据中心”。华为刚创下公司历史最高年收入。7nm 芯片本质上就是 Hopper 级别，当前主流模型大多在 Hopper 上训练。

出口管制适得其反。 限制迫使中国加速发展自己的芯片产业和技术栈，反而削弱了美国的技术领导力。美国电信产业就是前车之鉴——被政策“管”出了全球市场。

开发者生态才是关键。 全球 50% 的 AI 开发者在中国，他们目前在美国技术栈（Nvidia/CUDA）上开发。如果被迫离开，他们会转向中国自己的生态系统，未来的开源 AI 模型将优先为非美国硬件优化——这对美国才是真正的灾难。

Jensen 的核心主张：“不要用失败者的心态来制定政策。美国应该在 AI 五层蛋糕的每一层都去赢，而不是通过放弃市场来‘保护’自己。”

八、为什么不做多架构？“我们没有更好的想法”

当被问及为什么不像 Cerebras 或 Dojo 那样尝试完全不同的芯片架构时，Jensen 的回答简洁而自信：Nvidia 在模拟器中验证了所有这些替代方案，结果都可证明地更差。Nvidia 正在做的就是他们想做的项目。

唯一的例外是最近收购的 Groq——因为 token 的价值已经高到可以支撑不同的定价分层。高 ASP（平均售价）的低延迟 token 开辟了一个新的推理市场细分，这是 Nvidia 扩展帕累托前沿的方式。

九、如果没有深度学习革命？

Jensen 表示 Nvidia 依然会非常庞大。公司的根本前提是通用计算的扩展已经走到尽头，加速计算是唯一出路。即使没有 AI，分子动力学、量子化学、计算光刻、流体力学、粒子物理、数据处理等领域都需要 CUDA 加速。GTC 大会的开场部分——计算光刻、量子化学、数据处理——没有一项与 AI 相关，但每一项都至关重要。

总结：Jensen 的世界观

这场访谈揭示了 Jensen Huang 思考问题的底层框架：

1. **AI 是一个五层蛋糕**（能源 → 芯片 → 计算栈 → 模型 → 应用），每一层都必须成功
2. **生态系统比单一技术更重要**——开发者、安装基数、供应链信任构成了真正的壁垒
3. **极端主义是危险的**——无论是对 AI 安全的恐慌还是对出口管制的绝对化，都会导致适得其反的政策
4. **可编程性 > 专用化**——灵活的架构允许算法创新，而算法创新才是 AI 进步的真正引擎
5. **做尽可能少的事，但把必须做的事做到极致**——这是 Nvidia 30 年来的核心经营哲学